Araştırma Makalesi

Farklı Özellik Seçimi Yöntemlerinin Meme Kanseri Sınıflandırma Performansına Etkisinin Karşılaştırmalı Analizi

Comparative Analysis of the Effects of Different Feature Selection Methods on Breast Cancer Classification Performance

Muhammed Kılıç[1]

[1]Zonguldak Bülent Ecevit Üniversitesi, Fen Bilimleri Enstitüsü, Elektrik Elektronik Mühendisliği, Zonguldak, Türkiye

[1]Makalenin sorumlu yazarı E-posta: muhammed.kilic@fbe.karaelmas.edu.tr

Kısa Başlık: Meme Kanseri Sınıflandırmasında Özellik Seçimi

ORCID:

[1]https://orcid.org/0009-0007-6028-2395

Araştırma Makalesi

Farklı Özellik Seçimi Yöntemlerinin Meme Kanseri Sınıflandırma Performansına Etkisinin Karşılaştırmalı Analizi

Öz

Bu çalışmada, farklı özellik seçimi yöntemlerinin meme kanseri sınıflandırma performansı üzerindeki etkileri karşılaştırmalı olarak incelenmiştir. Çalışmada 569 gözlem ve 30 sayısal özellik içeren Breast Cancer Wisconsin (Diagnostic) veri seti kullanılmıştır. Veri seti %80 eğitim ve %20 test olarak ayrılmış, eğitim verileri üzerinde beş katlı tabakalı çapraz doğrulama uygulanmıştır. Özellik seçimi için ANOVA F-Test, Mutual Information ve Recursive Feature Elimination (RFE) yöntemleri kullanılarak her bir yöntemle 10 özellik belirlenmiştir. Seçilen özellikler k-En Yakın Komşu, Gaussian Naive Bayes ve Lojistik Regresyon algoritmalarıyla değerlendirilmiştir. Özellik seçimi uygulanmayan modeller temel karşılaştırma olarak çalışmaya dahil edilmiştir. Modellerin performansları doğruluk, duyarlılık, özgüllük, hassasiyet, F1-skoru ve ROC-AUC metrikleriyle değerlendirilmiştir. Deneysel sonuçlarda, özellik seçimi uygulanmayan Lojistik Regresyon modeli %98.25 test doğruluğuna ulaşmıştır. Özellik seçimi uygulanan modeller arasında RFE ile Lojistik Regresyon kombinasyonu %97.37 doğruluk ve 0.9967 ROC-AUC değeri elde etmiştir. Sonuçlar, özellik seçiminin sınıflandırma başarısını her durumda artırmadığını, ancak özellik sayısını azaltarak yüksek performansın korunmasına katkı sağlayabildiğini göstermiştir.

Anahtar kelimeler: Çapraz doğrulama, makine öğrenmesi, örüntü tanıma, performans değerlendirme, veri madenciliği.

Comparative Analysis of the Effects of Different Feature Selection Methods on Breast Cancer Classification Performance

Abstract

In this study, the effects of different feature selection methods on breast cancer classification performance were comparatively investigated. The Breast Cancer Wisconsin (Diagnostic) dataset, containing 569 samples and 30 numerical features, was used. The dataset was divided into 80% training and 20% testing subsets, and five-fold stratified cross-validation was applied to the training data. ANOVA F-Test, Mutual Information, and Recursive Feature Elimination

(RFE) were employed as feature selection methods, with 10 features selected by each method. The selected features were evaluated using k-Nearest Neighbors, Gaussian Naive Bayes, and Logistic Regression classifiers. Models without feature selection were also included as baseline approaches. Classification performance was evaluated using accuracy, sensitivity, specificity, precision, F1-score, and ROC-AUC metrics. Experimental results showed that Logistic Regression without feature selection achieved the highest test accuracy of 98.25%. Among the feature selection-based models, the combination of RFE and Logistic Regression achieved an accuracy of 97.37% and a ROC-AUC value of 0.9967. The findings indicate that feature selection does not necessarily improve classification accuracy in every case; however, it can reduce the number of input features while maintaining high classification performance.

Keywords: Cross-validation, data mining, machine learning, pattern recognition, performance evaluation.

1. Giriş

Örüntü tanıma, veriler içerisinde bulunan belirli yapıların ve ilişkilerin analiz edilerek gözlemlerin önceden tanımlanmış sınıflara atanmasını amaçlayan önemli bir araştırma alanıdır. Makine öğrenmesi yöntemlerinin gelişmesiyle birlikte örüntü tanıma uygulamaları, özellikle tıbbi verilerin analizinde ve bilgisayar destekli karar sistemlerinin geliştirilmesinde yaygın olarak kullanılmaktadır. Meme kanserinin sınıflandırılması da bu alandaki önemli uygulamalardan biridir. Hücresel yapıların sayısal özelliklerinden yararlanılarak iyi huylu ve kötü huylu tümörlerin birbirinden ayrılması, makine öğrenmesi yöntemlerinin değerlendirilmesine uygun bir sınıflandırma problemi oluşturmaktadır (Wolberg vd., 1993).

Sınıflandırma problemlerinde kullanılan veri setleri, hedef değişkenle farklı düzeylerde ilişkili çok sayıda özellik içerebilmektedir. Bununla birlikte bütün özelliklerin modele dahil edilmesi her zaman daha yüksek sınıflandırma başarısı sağlamamaktadır. Gereksiz veya birbiriyle yüksek düzeyde ilişkili özellikler, modelin karmaşıklığını artırabilmekte ve hesaplama maliyetini yükseltebilmektedir. Bu nedenle özellik seçimi, sınıflandırma modellerinin geliştirilmesinde önemli bir veri işleme aşaması olarak değerlendirilmektedir. Özellik seçimi yöntemleri, sınıflandırma açısından anlamlı değişkenlerin belirlenmesini ve daha az sayıda özellikle etkili modeller oluşturulmasını amaçlamaktadır (Guyon & Elisseeff, 2003).

Özellik seçimi yöntemleri farklı matematiksel yaklaşımlara dayanmaktadır. ANOVA F-Test yöntemi, özelliklerin sınıflar arasındaki ayırt ediciliğini istatistiksel olarak değerlendirirken Mutual Information yöntemi, özelliklerle hedef değişken arasındaki bilgi ilişkisini incelemektedir. Recursive Feature Elimination (RFE) yöntemi ise bir tahmin modelinden elde edilen önem değerlerinden yararlanarak özellikleri aşamalı biçimde elemektedir. Bu yöntemlerin seçtiği özellikler farklılık gösterebildiğinden sınıflandırma algoritmalarının performansları da değişebilmektedir.

Sınıflandırma başarısının güvenilir biçimde değerlendirilmesi için uygun veri bölme ve doğrulama yöntemlerinin kullanılması gerekmektedir. Çapraz doğrulama, eğitim verisinin farklı alt kümeler üzerinde değerlendirilmesini sağlayarak model performansının tek bir veri bölünmesine bağlı kalmasını azaltmaktadır (Kohavi, 1995). Ayrıca doğruluk değerinin tek başına yeterli olmadığı problemlerde duyarlılık, özgüllük, hassasiyet, F1-skoru ve ROC-AUC gibi ölçütlerin birlikte değerlendirilmesi önem taşımaktadır.

Bu çalışmada, Breast Cancer Wisconsin (Diagnostic) veri seti üzerinde ANOVA F-Test, Mutual Information ve RFE özellik seçimi yöntemlerinin sınıflandırma performansına etkilerinin karşılaştırılması amaçlanmıştır. Bu kapsamda k-En Yakın Komşu (k-NN), Gaussian Naive Bayes ve Lojistik Regresyon algoritmaları kullanılmıştır. Özellik seçimi uygulanmayan temel modeller ile özellik seçimi sonucunda oluşturulan modeller, beş katlı çapraz doğrulama ve bağımsız test verisi üzerinde değerlendirilmiştir. Böylece farklı özellik seçimi yöntemlerinin sınıflandırma başarısına etkileri, özellik sayısındaki azalma ve performans ölçütleri açısından karşılaştırmalı olarak incelenmiştir.

2. Materyal ve Yöntem(ler)

2.1. Materyal

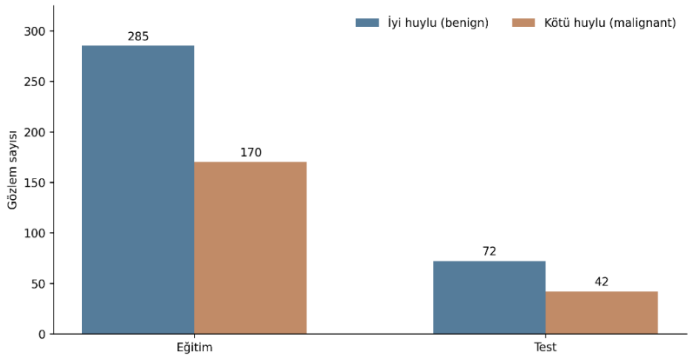
Bu çalışmada, UCI Machine Learning Repository üzerinde erişime açık olarak sunulan Breast Cancer Wisconsin (Diagnostic) veri seti kullanılmıştır. Veri seti, meme dokusundan ince iğne aspirasyonu yöntemiyle elde edilen hücre örneklerine ait sayısal ölçümlerden oluşmaktadır. Hücre çekirdeklerinin görüntülerinden çıkarılan özellikler kullanılarak tümörlerin iyi huylu (benign) veya kötü huylu (malignant) olarak sınıflandırılması amaçlanmaktadır (Wolberg vd., 1994).

Veri seti toplam 569 gözlem ve 30 sayısal giriş özelliği içermektedir. Gözlemlerin 357'si iyi huylu, 212'si ise kötü huylu sınıfa aittir. Giriş özellikleri; yarıçap, doku, çevre, alan, düzgünlük, kompaktlık, içbükeylik, içbükey nokta sayısı, simetri ve fraktal boyut gibi hücre çekirdeğine ilişkin 10 temel ölçümün ortalama, standart hata ve en büyük değerlerini kapsamaktadır. Kullanılan veri setinde eksik değer bulunmamaktadır.

Veri seti Python programlama dili ve Scikit-learn kütüphanesi aracılığıyla çalışma ortamına aktarılmıştır. Sınıflandırma modellerinin geliştirilmesi amacıyla veriler, sınıf dağılımları korunarak %80 eğitim ve %20 test olacak şekilde ayrılmıştır. Bu işlem sonucunda 455 gözlem eğitim, 114 gözlem ise test kümesine atanmıştır. Eğitim kümesinde 285 iyi huylu ve 170 kötü huylu, test kümesinde ise 72 iyi huylu ve 42 kötü huylu gözlem bulunmaktadır. Model geliştirme ve özellik seçimi işlemleri eğitim verileri üzerinde gerçekleştirilmiş, test kümesi ise nihai performans değerlendirmesi için ayrılmıştır. Çalışmada kullanılan veri setinin temel özellikleri sunulmuştur (Çizelge 1, Şekil 1).

Çizelge 1. Kullanılan veri setinin genel özellikleri.

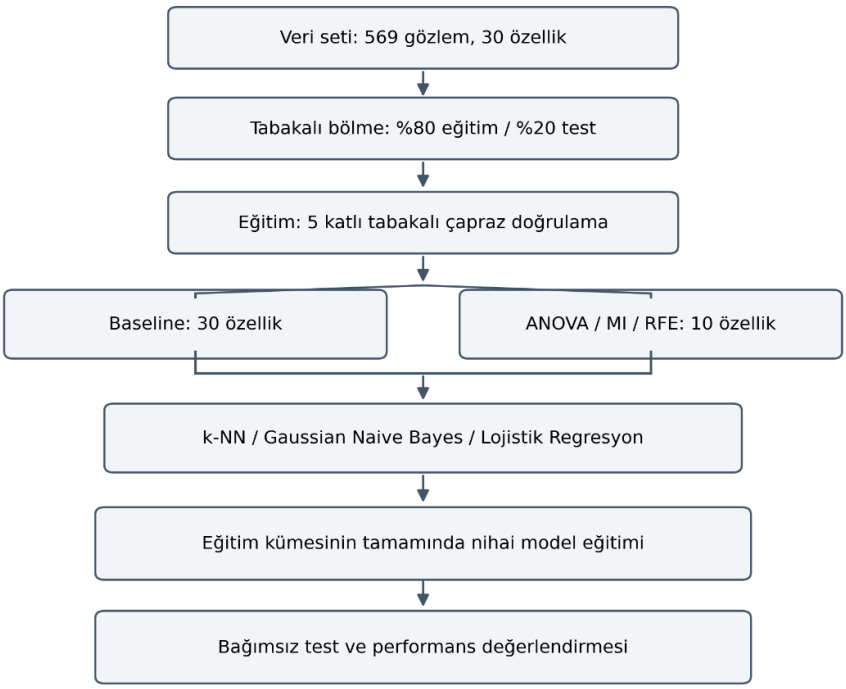
Özellik	Değer
Veri seti	Breast Cancer Wisconsin (Diagnostic)
Toplam gözlem	569
Giriş özelliği sayısı	30
Sınıf sayısı	2
İyi huylu gözlem	357
Kötü huylu gözlem	212
Eğitim kümesi	455 (%80)
Test kümesi	114 (%20)



Şekil 1. Eğitim ve test kümelerinin sınıf dağılımı.

2.2. Yöntem(ler)

Bu çalışmada, farklı özellik seçimi yöntemlerinin sınıflandırma performansı üzerindeki etkilerini değerlendirmek amacıyla karşılaştırmalı bir deneysel yaklaşım benimsenmiştir. Deneysel süreç; veri setinin eğitim ve test kümelerine ayrılması, özelliklerin standartlaştırılması, özellik seçimi, sınıflandırma modellerinin oluşturulması ve performans değerlendirmesi aşamalarından oluşmaktadır. Çalışmanın deneysel iş akış şeması sunulmuştur (Şekil 2).



Şekil 2. Çalışmanın deneysel iş akış şeması.

Veri seti, sınıf oranları korunarak %80 eğitim ve %20 test kümelerine ayrılmıştır. Veri bölme işleminde tekrarlanabilirliği sağlamak amacıyla rastgelelik değeri 42 olarak belirlenmiştir. Farklı ölçüm ölçeklerine sahip özelliklerin sınıflandırma algoritmaları üzerindeki etkisini azaltmak amacıyla standartlaştırma işlemi uygulanmıştır. Bu işlemde her özellik, eğitim verisinden hesaplanan ortalama ve standart sapma kullanılarak dönüştürülmüştür.

Model performanslarının değerlendirilmesinde beş katlı tabakalı çapraz doğrulama (Stratified 5-Fold Cross-Validation) yöntemi kullanılmıştır. Bu yöntemde eğitim verisi, sınıf dağılımları korunarak beş alt kümeye ayrılmıştır. Her yinelemede dört alt küme model eğitimi, kalan alt

küme ise doğrulama amacıyla kullanılmıştır. İşlem beş kez tekrarlanmış ve performans ölçütlerinin ortalama değerleri hesaplanmıştır.

Veri sızıntısını önlemek amacıyla standartlaştırma ve özellik seçimi işlemleri, çapraz doğrulamanın her yinelemesinde yalnızca ilgili eğitim alt kümesi üzerinde öğrenilmiştir. Böylece doğrulama verilerinden elde edilen bilgilerin model geliştirme sürecine dahil edilmesi engellenmiştir. Nihai modeller eğitim kümesinin tamamı kullanılarak eğitilmiş ve performansları daha önce model geliştirme aşamasında kullanılmayan bağımsız test kümesi üzerinde değerlendirilmiştir.

2.2.1. Özellik Seçimi Yöntemleri

Özellik seçimi, veri setinde bulunan değişkenler arasından sınıflandırma açısından anlamlı olanların belirlenmesini amaçlayan bir yöntemdir. Bu çalışmada, farklı değerlendirme yaklaşımlarına sahip ANOVA F-Test, Mutual Information ve Recursive Feature Elimination (RFE) yöntemleri kullanılmıştır. Yöntemlerin karşılaştırılabilirliğini sağlamak amacıyla her bir yöntemle 30 özellik arasından 10 özellik seçilmiştir. Böylece giriş özelliklerinin sayısı yaklaşık %66.67 oranında azaltılmıştır.

ANOVA F-Test: ANOVA F-Test, her bir özelliğin farklı sınıflardaki değerlerini karşılaştırarak sınıflar arasındaki değişimin sınıf içi değişime oranını değerlendiren istatistiksel bir yöntemdir. F-istatistiği yüksek olan özelliklerin sınıfları ayırt etme gücünün daha yüksek olduğu kabul edilmektedir. Bu çalışmada Scikit-learn kütüphanesindeki SelectKBest ve f_classif fonksiyonları kullanılarak en yüksek F-istatistiğine sahip 10 özellik belirlenmiştir.

Mutual Information: Mutual Information (Karşılıklı Bilgi), bir özellik ile hedef değişken arasındaki istatistiksel bağımlılığı ölçen bilgi kuramı temelli bir yöntemdir. Bu yaklaşım, doğrusal ilişkilerin yanı sıra doğrusal olmayan bağımlılıkların değerlendirilmesine de olanak sağlamaktadır. Karşılıklı bilgi değeri yüksek olan özellikler, hedef sınıf hakkında daha fazla bilgi taşıdıkları için tercih edilmektedir. Çalışmada mutual_info_classif fonksiyonu kullanılarak en yüksek karşılıklı bilgi değerine sahip 10 özellik seçilmiştir.

Recursive Feature Elimination (RFE): RFE, bir sınıflandırma veya regresyon modelinden elde edilen özellik önemlerini kullanarak daha az etkili özellikleri yinelemeli biçimde eleyen bir özellik seçimi yöntemidir. Her yinelemede özelliklerin önemleri yeniden değerlendirilerek

istenen özellik sayısına ulaşılıncaya kadar eleme işlemi sürdürülmektedir. Bu çalışmada RFE yönteminin temel tahmin modeli olarak Lojistik Regresyon kullanılmış ve 30 özellik arasından 10 özellik seçilmiştir.

Özellik seçimi yöntemlerinin sınıflandırma performansına etkisini değerlendirmek amacıyla özellik seçimi uygulanmayan modeller de temel karşılaştırma (baseline) olarak çalışmaya dahil edilmiştir. Böylece 30 özelliğin tamamını kullanan modeller ile seçilen 10 özelliği kullanan modeller aynı değerlendirme yaklaşımı altında karşılaştırılmıştır.

2.2.2. Sınıflandırma Algoritmaları

Bu çalışmada, özellik seçimi yöntemlerinin farklı sınıflandırma yaklaşımları üzerindeki etkilerini incelemek amacıyla k-En Yakın Komşu (k-NN), Gaussian Naive Bayes ve Lojistik Regresyon algoritmaları kullanılmıştır. Bu algoritmalar, sırasıyla uzaklık temelli, olasılıksal ve doğrusal karar modeli yaklaşımlarını temsil etmektedir. Her sınıflandırıcı, özellik seçimi uygulanmayan temel model ve üç farklı özellik seçimi yöntemiyle birlikte değerlendirilmiştir.

k-En Yakın Komşu (k-NN): k-NN, sınıflandırılacak bir gözlemin eğitim verisindeki en yakın k komşusunun sınıf bilgilerini kullanarak tahmin gerçekleştiren uzaklık temelli bir algoritmadır. Bu çalışmada komşu sayısı k = 5 olarak belirlenmiştir. Scikit-learn kütüphanesindeki KNeighborsClassifier algoritmasının varsayılan Öklid uzaklığı yaklaşımı kullanılmıştır. Özelliklerin farklı ölçüm aralıklarına sahip olması uzaklık hesaplamalarını etkileyebileceğinden sınıflandırma öncesinde standartlaştırma uygulanmıştır.

Gaussian Naive Bayes: Gaussian Naive Bayes, Bayes teoremine dayanan olasılıksal bir sınıflandırma algoritmasıdır. Bu yöntemde özelliklerin sınıf koşullu olasılık dağılımlarının Gaussian dağılımına uyduğu ve özelliklerin sınıf koşulunda birbirinden bağımsız olduğu varsayılmaktadır. Sınıflandırma işlemi, gözlemin her sınıfa ait olma olasılığının hesaplanması ve en yüksek olasılığa sahip sınıfın seçilmesiyle gerçekleştirilmektedir. Çalışmada GaussianNB algoritması varsayılan parametreleriyle kullanılmıştır.

Lojistik Regresyon: Lojistik Regresyon, iki sınıflı problemlerde bir gözlemin belirli bir sınıfa ait olma olasılığını lojistik fonksiyon aracılığıyla hesaplayan doğrusal bir sınıflandırma yöntemidir. Model, giriş özelliklerinin ağırlıklı toplamını kullanarak sınıf olasılıklarını belirlemektedir. Bu çalışmada LogisticRegression algoritması kullanılmış, optimizasyon

yöntemi olarak liblinear çözücüsü seçilmiş ve maksimum yineleme sayısı 5000 olarak belirlenmiştir.

Üç sınıflandırma algoritması, aynı eğitim ve test kümeleri üzerinde ve aynı çapraz doğrulama düzeni kullanılarak değerlendirilmiştir. Böylece gözlenen performans farklılıklarının kullanılan özellik seçimi yöntemi ve sınıflandırma algoritması açısından karşılaştırılması amaçlanmıştır. Toplamda, özellik seçimi uygulanmayan üç temel model ve özellik seçimi uygulanan dokuz model olmak üzere 12 farklı deneysel kombinasyon oluşturulmuştur. Özellik seçimi ve sınıflandırıcı kombinasyonları sunulmuştur (Çizelge 2).

Çizelge 2. Özellik seçimi ve sınıflandırıcı kombinasyonları.

Özellik seçimi	Özellik sayısı	Sınıflandırıcılar
Baseline	30	k-NN, Gaussian NB, Lojistik Regresyon
ANOVA F-Test	10	k-NN, Gaussian NB, Lojistik Regresyon
Mutual Information	10	k-NN, Gaussian NB, Lojistik Regresyon
RFE	10	k-NN, Gaussian NB, Lojistik Regresyon

2.2.3. Performans Değerlendirme Metrikleri

Bu çalışmada sınıflandırma modellerinin performanslarını kapsamlı biçimde değerlendirmek amacıyla doğruluk (accuracy), duyarlılık (sensitivity), özgüllük (specificity), hassasiyet (precision), F1-skoru ve ROC-AUC ölçütleri kullanılmıştır. Performans hesaplamalarında kötü huylu (malignant) tümörler pozitif, iyi huylu (benign) tümörler ise negatif sınıf olarak kabul edilmiştir.

Karmaşıklık matrisi, sınıflandırma sonuçlarının gerçek ve tahmin edilen sınıflara göre dağılımını göstermektedir. Bu matriste doğru pozitif (TP), kötü huylu olarak doğru sınıflandırılan gözlemleri; doğru negatif (TN), iyi huylu olarak doğru sınıflandırılan gözlemleri ifade etmektedir. Yanlış pozitif (FP), iyi huylu bir gözlemin kötü huylu olarak; yanlış negatif (FN) ise kötü huylu bir gözlemin iyi huylu olarak sınıflandırılması durumudur.

Doğruluk, doğru sınıflandırılan gözlemlerin toplam gözlem sayısına oranını ifade etmektedir. Duyarlılık, gerçek kötü huylu gözlemlerin ne kadarının doğru tespit edildiğini gösterirken özgüllük, gerçek iyi huylu gözlemlerin doğru belirlenme oranını göstermektedir. Hassasiyet, kötü huylu olarak tahmin edilen gözlemlerin ne kadarının gerçekten kötü huylu olduğunu ölçmektedir. F1-skoru ise hassasiyet ve duyarlılığın harmonik ortalamasıdır.

ROC (Receiver Operating Characteristic) eğrisi, farklı sınıflandırma eşiklerinde doğru pozitif oranı ile yanlış pozitif oranı arasındaki ilişkiyi göstermektedir. ROC eğrisinin altında kalan alanı ifade eden AUC (Area Under the Curve) değeri, modelin iki sınıfı birbirinden ayırt edebilme başarısını değerlendirmek amacıyla kullanılmıştır. ROC-AUC değerinin 1'e yaklaşması daha yüksek ayırt etme performansına işaret etmektedir.

Model performansları, eğitim verileri üzerinde gerçekleştirilen beş katlı çapraz doğrulama sonuçları ve bağımsız test kümesi sonuçları üzerinden karşılaştırılmıştır. Çapraz doğrulama aşamasında performans ölçütlerinin katlar boyunca elde edilen ortalamaları, test aşamasında ise nihai modellerin bağımsız gözlemler üzerindeki sonuçları değerlendirilmiştir. Performans metriklerinin matematiksel ifadeleri sunulmuştur (Çizelge 3).

Çizelge 3. Performans metriklerinin matematiksel ifadeleri.

Performans metriği	**Matematiksel ifade**
Doğruluk	$\frac{TP + TN}{TP + TN + FP + FN}$
Duyarlılık	$\frac{TP}{TP + FN}$
Özgüllük	$\frac{TN}{TN + FP}$
Hassasiyet	$\frac{TP}{TP + FP}$
F1-skoru	$\frac{2TP}{2TP + FP + FN}$
Yanlış pozitif oranı	$\frac{FP}{FP + TN}$

3. Bulgular ve Tartışma

Bu çalışmada, üç farklı özellik seçimi yöntemi ve üç sınıflandırma algoritması kullanılarak toplam 12 model kombinasyonu değerlendirilmiştir. Modellerin performansları, eğitim kümesi

üzerinde gerçekleştirilen beş katlı tabakalı çapraz doğrulama ve bağımsız test kümesinden elde edilen sonuçlar üzerinden incelenmiştir. Özellik seçimi uygulanmayan temel modeller ile ANOVA F-Test, Mutual Information ve RFE yöntemleri kullanılarak oluşturulan modeller karşılaştırılmıştır.

Özellik seçimi yöntemlerinin uygulanması sonucunda 30 giriş özelliği arasından her yöntem için 10 özellik belirlenmiştir. Yöntemler tarafından seçilen özellikler incelendiğinde ANOVA F-Test ve Mutual Information yöntemlerinin büyük ölçüde benzer değişkenleri tercih ettiği, RFE yönteminin ise farklı özellikleri de değerlendirmeye dahil ettiği görülmüştür. ANOVA F-Test ve Mutual Information yöntemleri arasında dokuz, ANOVA F-Test ile RFE arasında altı, Mutual Information ile RFE arasında ise altı ortak özellik belirlenmiştir. Üç yöntemin ortak olarak seçtiği özellikler mean area, worst radius, worst perimeter, worst area ve worst concave points değişkenleridir.

Bu durum, söz konusu özelliklerin farklı seçim yaklaşımlarında öne çıktığını göstermektedir. Ancak özelliklerin seçilmesi, tek başına sınıflandırma performansının artacağını garanti etmemektedir. Seçilen özelliklerin sınıflandırma başarısına etkisi sonraki deneysel sonuçlarla birlikte değerlendirilmiştir. Özellik seçimi yöntemlerinin belirlediği özellik sayıları ve yöntemler arasındaki ortak özelliklerin dağılımı sunulmuştur (Çizelge 4).

Çizelge 4. Özellik seçimi yöntemlerinin karşılaştırılması.

Özellik seçimi yöntemi	Seçilen özellik sayısı	ANOVA ile ortak	MI ile ortak	RFE ile ortak
ANOVA F-Test	10	10	9	6
Mutual Information	10	9	10	6
RFE	10	6	6	10

3.1. Çapraz Doğrulama Sonuçlarının Karşılaştırılması

Eğitim kümesi üzerinde gerçekleştirilen beş katlı tabakalı çapraz doğrulama sonucunda, özellik seçimi uygulanmayan Lojistik Regresyon modeli 0.9802 doğruluk, 0.9735 F1-skoru ve 0.9960 ROC-AUC değerleriyle en yüksek genel performansı göstermiştir. Özellik seçimi uygulanmayan k-NN modeli 0.9626 doğruluk elde ederken Gaussian Naive Bayes modeli 0.9341 doğruluk değerine ulaşmıştır.

Özellik seçimi uygulanan modeller incelendiğinde en yüksek çapraz doğrulama doğruluğu, RFE ve k-NN kombinasyonunda 0.9714 olarak elde edilmiştir. Aynı kombinasyon 0.9611 F1-skoru ve 0.9916 ROC-AUC değerlerine ulaşmıştır. RFE ile Lojistik Regresyon kombinasyonu ise 0.9648 doğruluk ve 0.9954 ROC-AUC değeri göstermiştir.

ANOVA F-Test ve Mutual Information yöntemlerinin sınıflandırma algoritmaları üzerindeki etkileri farklılık göstermiştir. ANOVA F-Test ile Gaussian Naive Bayes modelinin doğruluğu temel modele göre artarken, aynı yöntem Lojistik Regresyon modelinin doğruluğunda azalmaya neden olmuştur. Mutual Information yöntemiyle oluşturulan modellerin doğruluk değerleri ise ilgili temel modellerin altında kalmıştır.

Elde edilen bulgular, özellik seçimi yöntemlerinin sınıflandırma performansı üzerindeki etkisinin kullanılan algoritmaya bağlı olarak değiştiğini göstermektedir. Özellikle RFE yönteminin k-NN ve Gaussian Naive Bayes modellerinde olumlu sonuçlar verdiği, ancak hiçbir özellik seçimi kombinasyonunun temel Lojistik Regresyon modelinin çapraz doğrulama doğruluğunu aşamadığı belirlenmiştir. Farklı özellik seçimi yöntemleri ve sınıflandırma algoritmalarının beş katlı çapraz doğrulama sonuçları sunulmuştur (Çizelge 5).

Çizelge 5. Beş katlı çapraz doğrulama sonuçlarının karşılaştırılması.

Özellik seçimi	Sınıflandırıcı	Doğruluk	F1-skoru	ROC-AUC
Baseline	k-NN	0.9626	0.9490	0.9882
Baseline	Gaussian NB	0.9341	0.9106	0.9884
Baseline	Lojistik Regresyon	0.9802	0.9735	0.9960
ANOVA	k-NN	0.9429	0.9225	0.9759
ANOVA	Gaussian NB	0.9429	0.9244	0.9818
ANOVA	Lojistik Regresyon	0.9473	0.9293	0.9869
Mutual Information	k-NN	0.9429	0.9223	0.9718
Mutual Information	Gaussian NB	0.9297	0.9019	0.9816

Mutual Information	Lojistik Regresyon	0.9363	0.9142	0.9869
RFE	k-NN	0.9714	0.9611	0.9916
RFE	Gaussian NB	0.9495	0.9301	0.9905
RFE	Lojistik Regresyon	0.9648	0.9519	0.9954

3.2. Bağımsız Test Sonuçlarının Karşılaştırılması

Eğitim kümesi üzerinde geliştirilen sınıflandırma modelleri, 114 gözlem içeren bağımsız test kümesi üzerinde değerlendirilmiştir. Elde edilen sonuçlara göre özellik seçimi uygulanmayan Lojistik Regresyon modeli, 0.9825 doğruluk, 0.9762 duyarlılık, 0.9861 özgüllük, 0.9762 hassasiyet, 0.9762 F1-skoru ve 0.9957 ROC-AUC değeriyle en yüksek test doğruluğuna ulaşmıştır. Bu model, test kümesindeki 114 gözlemden 112'sini doğru sınıflandırmıştır.

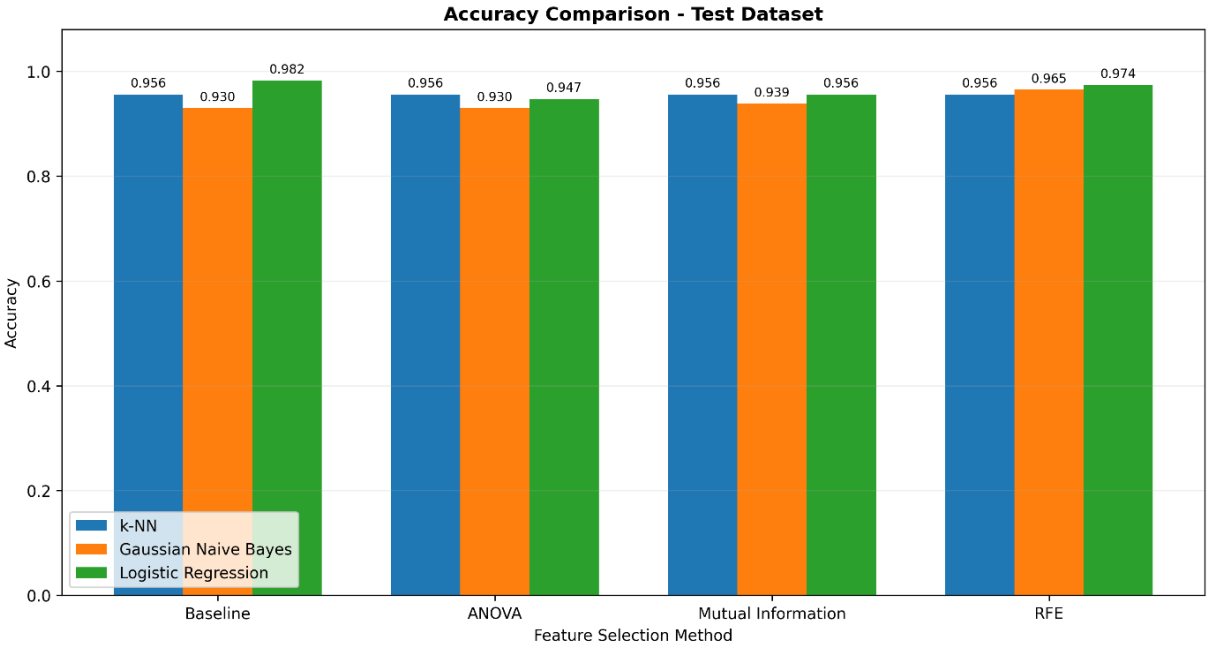
Özellik seçimi uygulanan modeller arasında en yüksek test doğruluğu, RFE ile Lojistik Regresyon kombinasyonunda 0.9737 olarak elde edilmiştir. Bu modelde 30 giriş özelliği 10'a düşürülmesine rağmen 0.9647 F1-skoru ve 0.9967 ROC-AUC değerlerine ulaşılmıştır. RFE ile Gaussian Naive Bayes kombinasyonu ise 0.9649 doğruluk ve 0.9512 F1-skoru elde ederek özellik seçimi uygulanmayan Gaussian Naive Bayes modelinden daha başarılı olmuştur.

k-NN algoritmasında bütün özellik seçimi yöntemleri için test doğruluğu 0.9561 olarak gerçekleşmiştir. Bununla birlikte ROC-AUC değerlerinde farklılıklar gözlenmiştir. Bu durum, aynı sınıflandırma doğruluğuna sahip modellerin sınıfları farklı eşik değerlerinde ayırt etme performanslarının değişebileceğini göstermektedir.

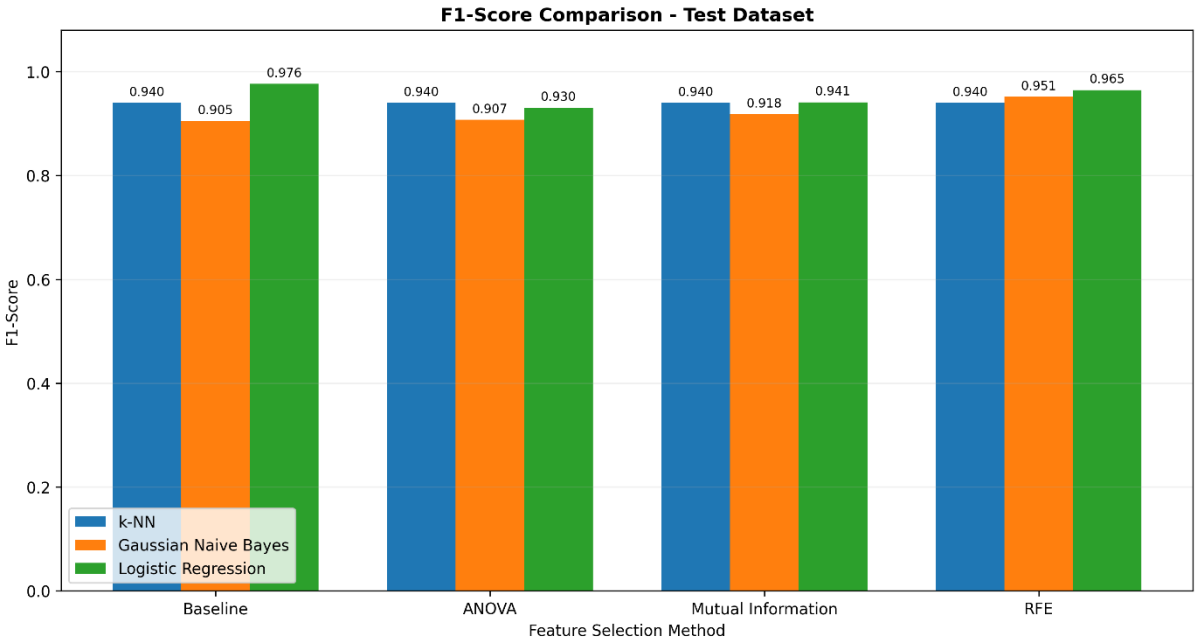
Genel olarak değerlendirildiğinde, özellik seçiminin bütün sınıflandırıcılarda doğruluk artışı sağlamadığı, ancak bazı model kombinasyonlarında daha az sayıda özellikle yüksek sınıflandırma performansının korunduğu belirlenmiştir. Özellikle RFE yönteminin Gaussian Naive Bayes ve Lojistik Regresyon algoritmalarıyla birlikte kullanıldığında başarılı sonuçlar verdiği görülmüştür. Bağımsız test kümesinde elde edilen doğruluk, duyarlılık, özgüllük, hassasiyet, F1-skoru ve ROC-AUC sonuçları sunulmuştur (Çizelge 6). Modellerin bağımsız test kümesinde elde ettiği doğruluk, F1-skoru ve ROC-AUC değerlerinin karşılaştırmalı gösterimleri sırasıyla verilmiştir (Şekil 3, Şekil 4, Şekil 5).

Çizelge 6. Bağımsız test kümesi sınıflandırma sonuçları.

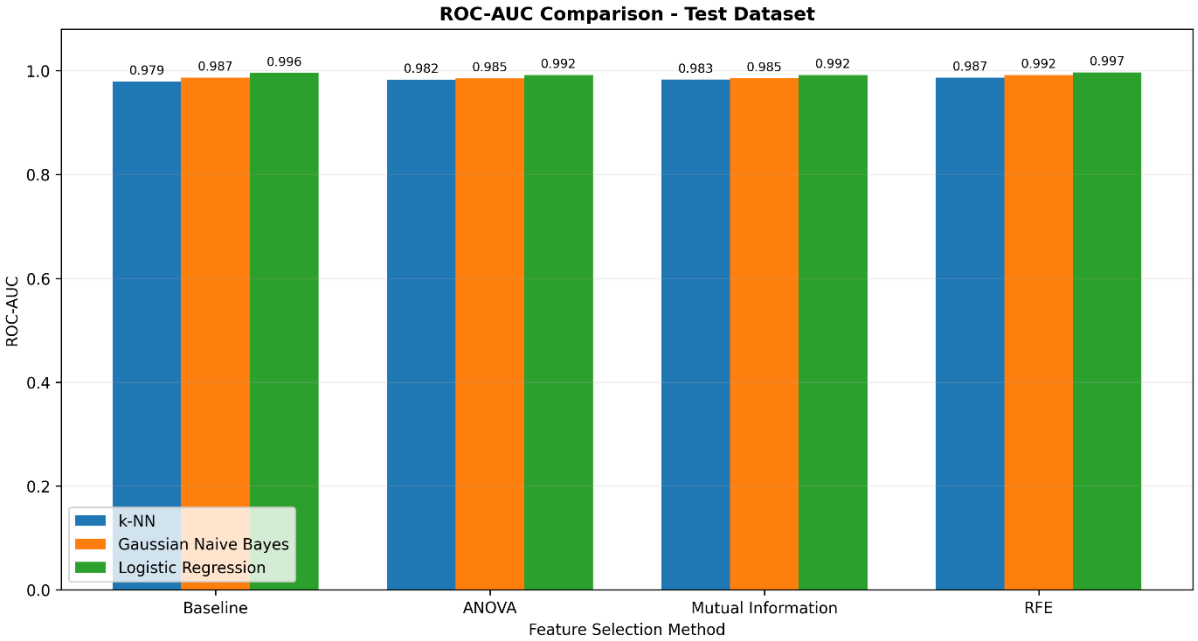
Özellik seçimi	Model	D	Du	Ö	H	F1	AUC
Baseline	k-NN	.9561	.9286	.9722	.9512	.9398	.9788
Baseline	GNB	.9298	.9048	.9444	.9048	.9048	.9868
Baseline	LR	.9825	.9762	.9861	.9762	.9762	.9957
ANOVA	k-NN	.9561	.9286	.9722	.9512	.9398	.9825
ANOVA	GNB	.9298	.9286	.9306	.8864	.9070	.9851
ANOVA	LR	.9474	.9524	.9444	.9091	.9302	.9917
MI	k-NN	.9561	.9286	.9722	.9512	.9398	.9826
MI	GNB	.9386	.9286	.9444	.9070	.9176	.9854
MI	LR	.9561	.9524	.9583	.9302	.9412	.9917
RFE	k-NN	.9561	.9286	.9722	.9512	.9398	.9866
RFE	GNB	.9649	.9286	.9861	.9750	.9512	.9917
RFE	LR	.9737	.9762	.9722	.9535	.9647	.9967



Şekil 3. Farklı model kombinasyonlarının test doğruluklarının karşılaştırılması.



Şekil 4. Farklı model kombinasyonlarının F1-skorlarının karşılaştırılması.



Şekil 5. Farklı model kombinasyonlarının ROC-AUC değerlerinin karşılaştırılması.

3.3. ROC Eğrileri ve Karmaşıklık Matrislerinin Değerlendirilmesi

Sınıflandırma modellerinin farklı karar eşiklerinde gösterdiği performansı değerlendirmek amacıyla ROC eğrileri incelenmiştir. Modellerin ROC-AUC değerleri karşılaştırıldığında, özellik seçimi uygulanmayan Lojistik Regresyon modelinin 0.9957, RFE ile Lojistik Regresyon kombinasyonunun ise 0.9967 değerine ulaştığı görülmüştür. RFE ile Lojistik Regresyon modeli, daha az sayıda özellik kullanmasına rağmen test kümesindeki en yüksek ROC-AUC

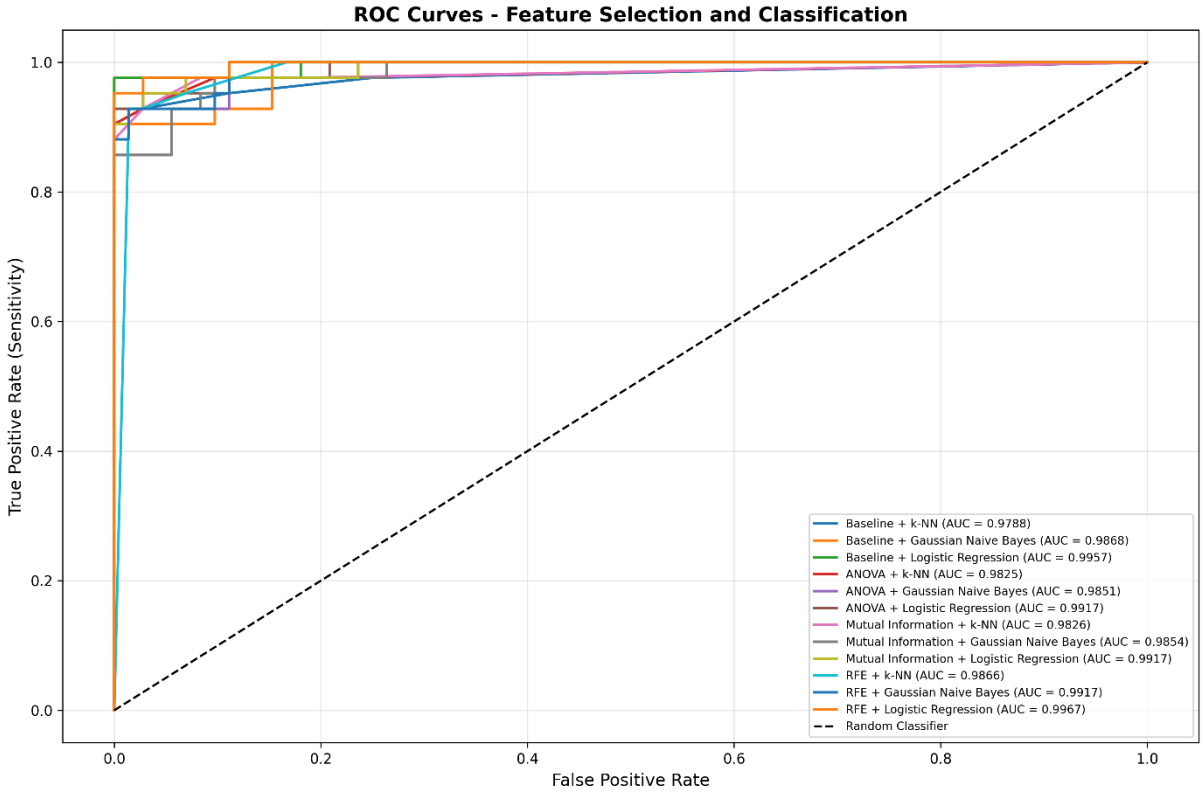
değerini elde etmiştir. Bu sonuç, özellik sayısının azaltılmasının bazı model kombinasyonlarında sınıflar arasındaki ayırt ediciliği koruyabildiğini göstermektedir.

Karmaşıklık matrisleri incelendiğinde, özellik seçimi uygulanmayan Lojistik Regresyon modelinin 42 kötü huylu gözlemden 41'ini doğru sınıflandırdığı, bir kötü huylu gözlemi ise yanlışlıkla iyi huylu olarak değerlendirdiği belirlenmiştir. Aynı model, 72 iyi huylu gözlemden 71'ini doğru sınıflandırmıştır. Böylece toplam 114 test gözleminin 112'si doğru tahmin edilmiştir.

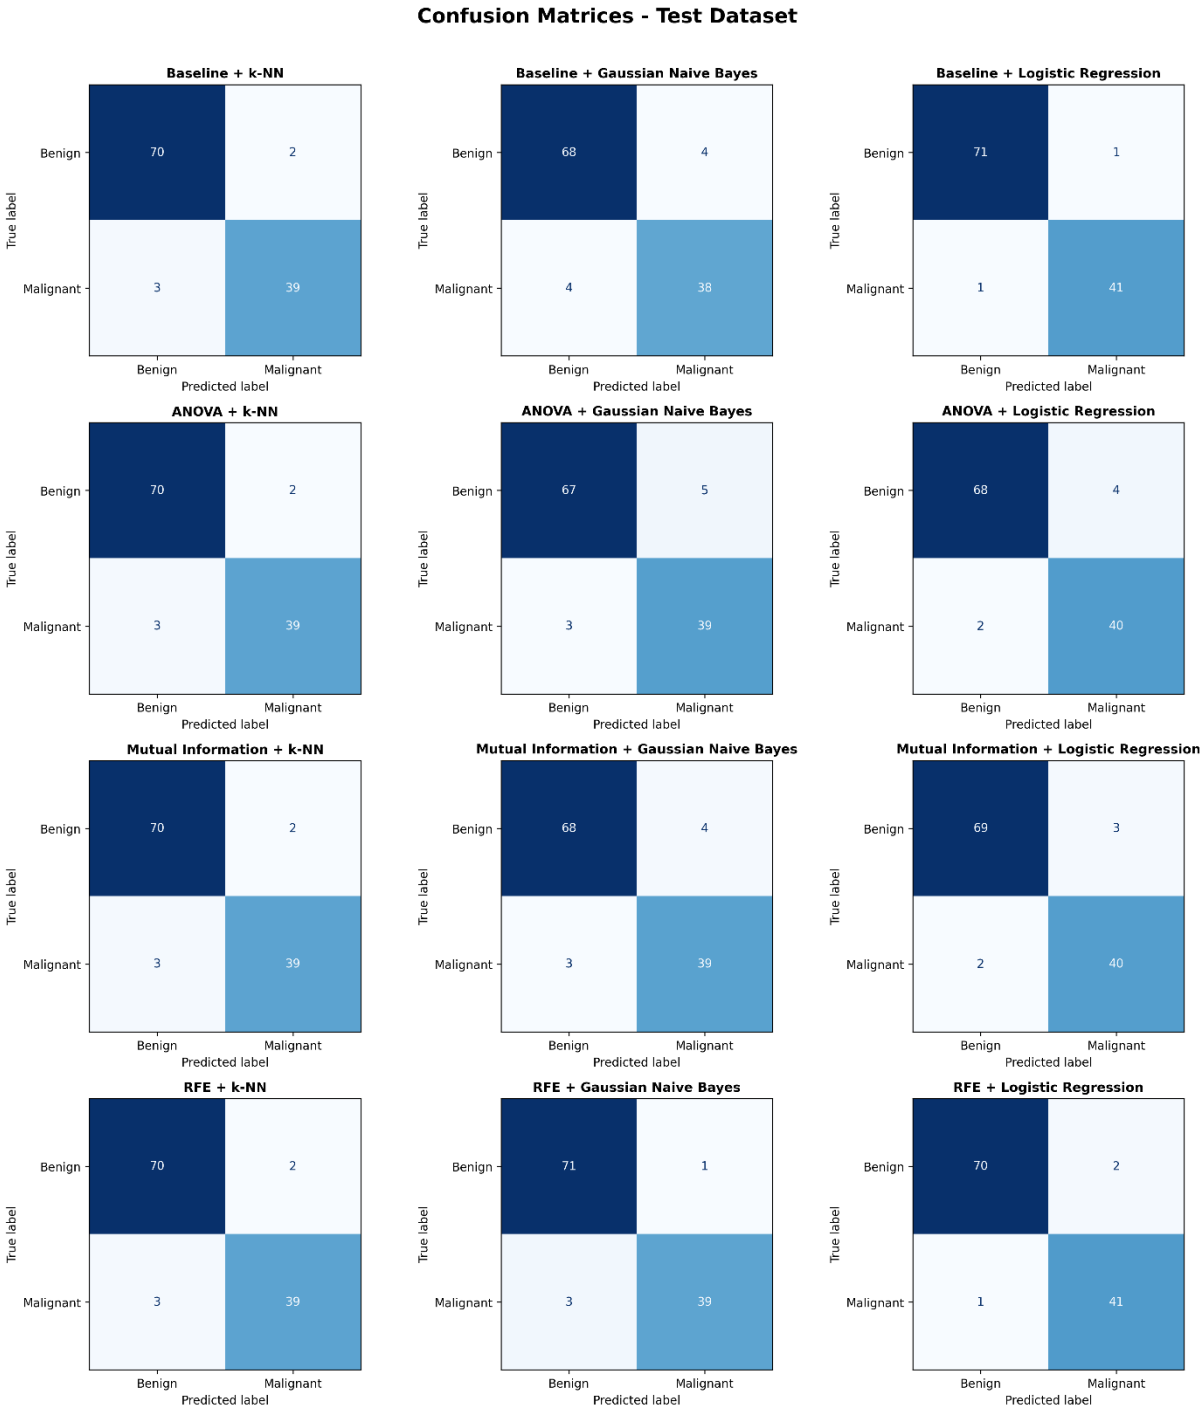
RFE ile Lojistik Regresyon kombinasyonunda ise 41 kötü huylu ve 70 iyi huylu gözlem doğru sınıflandırılmıştır. Bu modelde bir yanlış negatif ve iki yanlış pozitif tahmin bulunmaktadır. Dolayısıyla RFE ile Lojistik Regresyon modeli, temel Lojistik Regresyon modeliyle aynı duyarlılık değerine ulaşırken daha düşük özgüllük göstermiştir.

Meme kanseri sınıflandırması açısından yanlış negatif tahminler özellikle önemlidir. Kötü huylu bir gözlemin iyi huylu olarak sınıflandırılması, olası bir hastalık durumunun gözden kaçırılması anlamına gelebilmektedir. Bu nedenle modellerin yalnızca genel doğruluk değerleriyle değil, duyarlılık ve yanlış negatif sayılarıyla birlikte değerlendirilmesi gerekmektedir. Bununla birlikte çalışmada elde edilen bulgular, kullanılan veri seti ve deneysel koşullarla sınırlıdır; sonuçlar doğrudan klinik tanı başarısı olarak yorumlanmamalıdır.

Genel olarak ROC eğrileri ve karmaşıklık matrisleri, özellik seçimi uygulanmayan Lojistik Regresyon modelinin yüksek sınıflandırma doğruluğu sağladığını, RFE ile Lojistik Regresyon kombinasyonunun ise 10 özellikle benzer düzeyde duyarlılık ve yüksek ROC-AUC performansı elde ettiğini ortaya koymaktadır. Modellerin ROC eğrileri Şekil 6'da, bağımsız test kümesine ait karmaşıklık matrisleri ise Şekil 7'de sunulmuştur.



Şekil 6. Farklı özellik seçimi ve sınıflandırıcı kombinasyonlarına ait ROC eğrileri.



Şekil 7. Sınıflandırma modellerinin bağımsız test kümesine ait karmaşıklık matrisleri.

4. Sonuç ve Öneriler

Bu çalışmada, meme kanseri sınıflandırmasında farklı özellik seçimi yöntemlerinin sınıflandırma performansı üzerindeki etkileri karşılaştırmalı olarak incelenmiştir. Breast Cancer Wisconsin Diagnostic veri setinde bulunan 30 özellik, ANOVA F-Test, Mutual Information ve RFE yöntemleri kullanılarak 10 özelliğe indirgenmiştir. Özellik seçimi uygulanmayan temel

modeller de değerlendirmeye dahil edilerek k-NN, Gaussian Naive Bayes ve Lojistik Regresyon algoritmalarıyla toplam 12 model kombinasyonu oluşturulmuştur.

Beş katlı çapraz doğrulama sonuçlarına göre en yüksek doğruluk değeri, özellik seçimi uygulanmayan Lojistik Regresyon modeliyle 0.9802 olarak elde edilmiştir. Bağımsız test kümesinde de aynı model 0.9825 doğruluk, 0.9762 duyarlılık ve 0.9957 ROC-AUC değerlerine ulaşarak en yüksek test doğruluğunu sağlamıştır. Özellik seçimi uygulanan modeller arasında RFE ile Lojistik Regresyon kombinasyonu 0.9737 test doğruluğu ve 0.9967 ROC-AUC değeriyle öne çıkmıştır.

Elde edilen bulgular, özellik seçiminin her durumda sınıflandırma doğruluğunu artırmadığını, ancak uygun yöntem ve sınıflandırıcı kombinasyonlarıyla daha az sayıda özellik kullanılarak yüksek performansın korunabildiğini göstermiştir. RFE yöntemiyle özellik sayısının 30'dan 10'a düşürülmesi, giriş boyutunda yaklaşık %66.67 oranında azalma sağlamıştır. Bununla birlikte sınıflandırma başarısının değerlendirilmesinde yalnızca doğruluk değil, özellikle kötü huylu tümörlerin tespit edilmesini ifade eden duyarlılık ve yanlış negatif sonuçlar da dikkate alınmalıdır.

Gelecek çalışmalarda farklı özellik sayıları, ek sınıflandırma algoritmaları ve farklı veri setleri kullanılarak yöntemlerin genellenebilirliği araştırılabilir. Ayrıca hiperparametre optimizasyonu ve özellik seçimi yöntemlerinin birlikte değerlendirilmesiyle sınıflandırma performansının geliştirilmesi hedeflenebilir. Çalışmada elde edilen sonuçların kullanılan veri setiyle sınırlı olduğu ve klinik uygulamalar için bağımsız doğrulama çalışmalarına ihtiyaç duyulduğu göz önünde bulundurulmalıdır.

Teşekkür: Bu çalışma kapsamında herhangi bir kurum veya kuruluştan finansal destek alınmamıştır. Yazar, çalışmayla ilgili herhangi bir çıkar çatışması bulunmadığını beyan etmektedir.

Yazar katkısı: Muhammed Kılıç; çalışmanın planlanması, veri setinin hazırlanması, özellik seçimi ve sınıflandırma algoritmalarının uygulanması, deneysel sonuçların analiz edilmesi ve makalenin hazırlanması aşamalarını gerçekleştirmiştir.

Etik kurul onayı: Bu çalışmada kamuya açık ve kimlik bilgisi içermeyen Breast Cancer Wisconsin (Diagnostic) veri seti kullanılmıştır. İnsan katılımcılardan doğrudan veri toplanmadığı ve herhangi bir klinik müdahale gerçekleştirilmediği için etik kurul onayı gerektiren bir araştırma yürütülmemiştir.

Kaynaklar

Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13(1), 21–27. https://doi.org/10.1109/TIT.1967.1053964

Duda, R. O., Hart, P. E., & Stork, D. G. (2001). Pattern classification (2nd ed.). Wiley.

Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. Journal of Machine Learning Research, 3, 1157–1182.

Guyon, I., Weston, J., Barnhill, S., & Vapnik, V. (2002). Gene selection for cancer classification using support vector machines. Machine Learning, 46, 389–422. https://doi.org/10.1023/A:1012487302797

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In Proceedings of the 14th International Joint Conference on Artificial Intelligence (pp. 1137–1145).

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Peng, H., Long, F., & Ding, C. (2005). Feature selection based on mutual information: Criteria of max-dependency, max-relevance, and min-redundancy. IEEE Transactions on Pattern Analysis and Machine Intelligence, 27(8), 1226–1238. https://doi.org/10.1109/TPAMI.2005.159

Street, W. N., Wolberg, W. H., & Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. In Electronic Imaging: Science and Technology. SPIE.

Wolberg, W. H., Street, W. N., & Mangasarian, O. L. (1994). Machine learning techniques to diagnose breast cancer from image-processed nuclear features of fine needle aspirates. Cancer Letters, 77(2–3), 163–171. https://doi.org/10.1016/0304-3835(94)90099-X

Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1993). Breast Cancer Wisconsin (Diagnostic) [Data set]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B